Intelligente Untertitel: Automatische Anpassung der Untertiteldarstellung basierend auf Audio- und Textverständlichkeit

Kilian Kienast

10. August 2025

https://github.com/dieBaerigenBerchtesgadener/Intelligent-Subtitles/
kilian.kienast@gmx.de

Zusammenfassung

Diese Arbeit adressiert die Limitationen konventioneller Untertitelsysteme durch die Entwicklung eines adaptiven Ansatzes, der Untertitel bedarfsorientiert basierend auf Audio- und Textverständlichkeit einblendet. Herkömmliche permanente Untertitel führen häufig zu visueller Ablenkung, Bildverdeckung und unnötigem Mitlesen, während ihr vollständiges Fehlen das Verständnis fremdsprachiger Inhalte signifikant beeinträchtigen kann. Die vorgestellte Methodik kombiniert neun sorgfältig entwickelte Features (Wortkomplexität, Satzkomplexität, Wortwichtigkeit, Wortvorkommen, Wortbekanntheit, Audiokomplexität, Sprechgeschwindigkeit, Umgebungslautstärke und relative Lautstärke) mit Nutzerpräferenzen in einer Pipeline, die durch ein Extreme Gradient Boosting Modell zur selektiven Untertiteldarstellung führt. Die quantitative Evaluation zeigt vielversprechende Ergebnisse mit einem F2-Score von 0,6122, einer Balanced Accuracy von 0,8064 und einem ROC-AUC-Wert von 0,8927. Das Modell demonstriert besondere Stärke in der Unterdrückung unnötiger Untertitel (Präzision von 0,97 für die Klasse "Nicht-Anzeigen"), weist jedoch Optimierungspotenzial bei der Präzision für die Klasse Änzeigen"(0,37) auf. Die Analyse der Feature-Relevanz identifiziert Sprachlevel der Nutzenden, Wortbekanntheit und Worthäufigkeit als besonders einflussreich für die Modellentscheidungen. Die Ergebnisse bestätigen die grundsätzliche Machbarkeit adaptiver Untertitelsysteme und zeigen gleichzeitig spezifische Richtungen für zukünftige Optimierungen auf, insbesondere hinsichtlich der Erweiterung des Trainingssets und der Verfeinerung der Feature-Extraktion.

Inhaltsverzeichnis

Inhaltsverzeichnis **1**

1 Fachliche Kurzfassung **2**

2 Motivation und Fragestellung **3**

3 Hintergrund und theoretische Grundlagen **3**

4 Vorgehensweise, Materialien und Methoden **4**
4.1 Aufbau der Pipeline 4
4.2 Extraktion der Features 5
4.2.1 Wortkomplexität 5
4.2.2 Satzkomplexität 5
4.2.3 Wortwichtigkeit 5
4.2.4 Wortvorkommen 5
4.2.5 Wortbekanntheit 6
4.2.6 Audiokomplexität 6
4.2.7 Sprechgeschwindigkeit 6
4.2.8 Umgebungslautstärke 7
4.2.9 Relative Lautstärke 7
4.3 Kontextabhängige Übersetzung 8
4.4 Extreme Gradient Boosting zur Entscheidungsfindung 8
4.4.1 Trainingsset 8
4.4.2 Hyperparameter und Trainingsdetails 9

5 Ergebnisse **9**
5.1 Leistungsbewertung des Modells 9
5.2 Klassifikationsbericht 10
5.3 Feature Importance Analyse 10
5.4 Einfluss der Trainingssetgröße 11

6 Ergebnisdiskussion **12**

7 Fazit und Ausblick **14**

8 Literaturverzeichnis **15**

9 Unterstützungsleistungen **17**

1 Fachliche Kurzfassung

Diese Arbeit präsentiert ein System zur dynamischen Anpassung der Untertiteldarstellung, das auf der Analyse von Audio- und Textverständlichkeit basiert. Ziel ist es, Untertitel gezielt und nutzerzentriert einzublenden, um visuelle Ablenkungen zu minimieren und die Verständlichkeit zu maximieren. Aufgrund fehlender umfangreicher Trainingsdaten wurde eine Pipeline entwickelt, die neun zentrale Features kombiniert:

- **Wortkomplexität:** Die linguistische Schwierigkeit von Wörtern wird durch Zuordnung zu CEFR-Leveln (A1 bis C2) bewertet.
- **Satzkomplexität:** Die strukturelle und semantische Komplexität eines Satzes wird mithilfe eines Pretrained Encoder-Only Models, auch Pretrained Transformer (PT), eingeschätzt.
- **Wortwichtigkeit:** Essenzielle Wörter im Kontext eines Satzes werden identifiziert, indem sie maskiert werden und ihre Erwartbarkeit mit einem PT bewertet wird.
- **Wortvorkommen:** Die Häufigkeit eines Wortes im Video wird genutzt, um redundante Untertitel zu vermeiden.
- **Wortbekanntheit:** Die Alltagshäufigkeit von Wörtern wird bewertet.
- **Audiokomplexität:** Basierend auf der Unsicherheitsbewertung der von einem automatischen Spracherkennungssystem (ASR, Automatic Speech Recognition) extrahierten Transkriptionen wird die Schwierigkeit des Audiosignals analysiert.
- **Sprechgeschwindigkeit:** Die Silbenrate pro Sekunde wird für jeden Satz berechnet.
- **Umgebungslautstärke:** Das Verhältnis zwischen Sprechlautstärke und Hintergrundgeräuschen wird analysiert, um schwer verständliche Wörter zu identifizieren.
- **Relative Lautstärke:** Die relative Lautstärke eines Satzes wird bewertet.

Zusätzlich zu den genannten Features werden zwei Selbsteinschätzungen der Nutzenden zum Englischlevel und zum Audioverständnis als Eingabe für ein Extreme Gradient Boosting Model verwendet, das darauf trainiert wurde, Untertitel adaptiv anzuzeigen oder auszublenden. Das Modell wurde mit einem Datenset aus ca. 40.000 gelabelten Wörtern trainiert und getestet, wobei die Testgröße 20 % entsprach. Die Evaluation auf dem Testset ergab eine Balanced Accuracy von 0.8064 und einen ROC-AUC-Wert von 0.8927, was die grundsätzliche Fähigkeit des Modells zur Unterscheidung beider Klassen bestätigt. Die Klasse 1 (Anzeigen) erreicht einen Recall von 0.73, sodass ein Großteil der notwendigen Untertitel erkannt wird. Die Präzision für diese Klasse ist mit 0.37 jedoch gering, was auf eine relevante Anzahl fälschlicherweise angezeigter Untertitel (False Positives) hindeutet. Für die Klasse 0 (Nicht-Anzeigen) erzielt das Modell hingegen eine hohe Präzision von 0.97, wodurch unnötige Untertitel effektiv unterdrückt werden.

Zusammenfassend demonstriert die Arbeit das Potenzial adaptiver Untertitelsysteme zur Reduktion visueller Überladung bei gleichzeitiger Verständlichkeitsunterstützung. Zukünftige Arbeiten sollten sich auf die Verbesserung der Präzision (Reduktion von False Positives), die Optimierung der Pipeline-Geschwindigkeit und die Erweiterung des Trainingssets um diversere Nutzerprofile und Inhalte konzentrieren, um die Generalisierbarkeit und individuelle Anpassungsfähigkeit zu erhöhen.

2 Motivation und Fragestellung

Audiovisuelle Medien mit Untertiteln spielen eine zentrale Rolle in der modernen Gesellschaft, sowohl im Bereich der Barrierefreiheit für Personen mit Hörbeeinträchtigungen (Bundesfachstelle Barrierefreiheit, 2022) als auch beim Fremdsprachenerwerb und -konsum (Schmidt-Weigand et al., 2017). Aktuelle Untersuchungen zeigen, dass mehr als die Hälfte der Zuschauenden regelmäßig Untertitel nutzen (Preply, 2022). Die wachsende Relevanz von Untertitelsystemen steht jedoch im Widerspruch zu den bestehenden Limitationen: Permanente Untertitel führen häufig zu visueller Ablenkung, verdecken relevante Bildelemente und können kognitive Ressourcen durch unnötiges Mitlesen beanspruchen (Schmidt-Weigand et al., 2017). Ohne Untertitel hingegen wird das Verständnis fremdsprachiger Inhalte erschwert, insbesondere bei komplexer Sprache, schnellem Sprechtempo oder störenden Hintergrundgeräuschen.

Die Forschung zu adaptiven Mediensystemen hat in den letzten Jahren erhebliche Fortschritte erzielt. Hu et al. (2014) entwickelten dynamische Untertitelsysteme, die Untertitel basierend auf der Position des Sprechers platzieren. Akahori et al. (2017) sowie Kurzhals et al. (2020) erweiterten diesen Ansatz durch die Berücksichtigung der Blickposition des Zuschauenden. Gorman et al. (2021) führten ein nutzerzentriertes System ein, das personalisierte Entscheidungen ermöglicht, indem Zuschauende selbst bestimmen können, für welche Filmcharaktere Untertitel angezeigt werden sollen. Diese Studien fokussieren sich jedoch primär auf die räumliche Positionierung der Untertitel, während die adaptive Steuerung der Sichtbarkeit von Untertiteln basierend auf der tatsächlichen Notwendigkeit bisher unzureichend erforscht wurde.

Die vorliegende Arbeit adressiert diese Forschungslücke durch die Entwicklung und Evaluation eines Systems zur bedarfsorientierten Ein- und Ausblendung von Untertiteln. Im Gegensatz zu bestehenden Ansätzen berücksichtigt dieses System nicht nur die visuelle Darstellung, sondern integriert eine umfassende Analyse der Verstehbarkeit des Audiosignals und der sprachlichen Komplexität in Kombination mit individuellen Nutzerpräferenzen. Die zentrale Forschungsfrage lautet: Inwieweit kann ein auf Audio- und Textmerkmalen basierendes Modell die adaptive Anzeige von Untertiteln präzise steuern und damit die Nachteile konventioneller Untertitelsysteme überwinden?

Die Arbeit basiert auf der Hypothese, dass eine Kombination aus Audiokomplexitäts-, Textmerkmalen und nutzerspezifischen Faktoren ausreichend sein kann, um ein effektives adaptives Untertitelsystem zu entwickeln. Um diese Hypothese zu überprüfen, wurde ein Modell entwickelt und anhand quantitativer Metriken sowie nutzerzentrierter Evaluationen bewertet.

3 Hintergrund und theoretische Grundlagen

Ein zentrales Problem war das Fehlen eines geeigneten Trainingssets. Ein solches Set müsste nicht nur Bewertungen der Schwierigkeit einzelner Wörter enthalten, sondern auch Informationen über die Audio- und Textverständlichkeitsniveaus der Nutzenden. Tiefe neuronale Netze wie Transformer (Vaswani et al., 2017), RNNs (Karpathy, 2015) oder LSTMs (Hochreiter and Schmidhuber, 1997) benötigen in der Regel zudem große Datensätze zum Training bzw. Posttraining. Da ein solches Datenset nicht verfügbar war, wurde eine Pipeline entwickelt, die neun zentrale Features extrahiert, um die Verstehbarkeit von Audio und Text ohne ein umfangreiches Trainingsset zu modellieren: Wortkomplexität, Satzkomplexität, Wortwichtigkeit, Wortvorkommen, Wortbekanntheit, Audiokomplexität, Sprechgeschwindigkeit, Umgebungslautstärke, Relative Lautstärke.

4 Vorgehensweise, Materialien und Methoden

4.1 Aufbau der Pipeline

Die Pipeline benötigt als Eingabe das Audio eines Videos sowie die originalen Untertitel. Zuerst erfolgt eine manuelle Bereinigung, bei der Laute oder irrelevante Wörter entfernt und nicht-englische Wörter markiert werden. In den weiteren Verarbeitungsschritten werden dann die neun zentralen Features extrahiert. Die Untertitel werden zusätzlich ins Deutsche übersetzt, um später auch zweisprachige Untertitel bzw. ausschließlich die Übersetzung schwerer Wörter anzuzeigen. Ein selbsttrainiertes Extreme Gradient Boosting Model verarbeitet die extrahierten Features und die Angaben zur Audio- und Textverständlichkeit der Nutzenden und trifft die finale Entscheidung über die Anzeige der Untertitel. Als Ergebnis liefert die Pipeline optimierte Untertitel, die nur dann eingeblendet werden, wenn sie für das Verständnis wirklich notwendig sind.

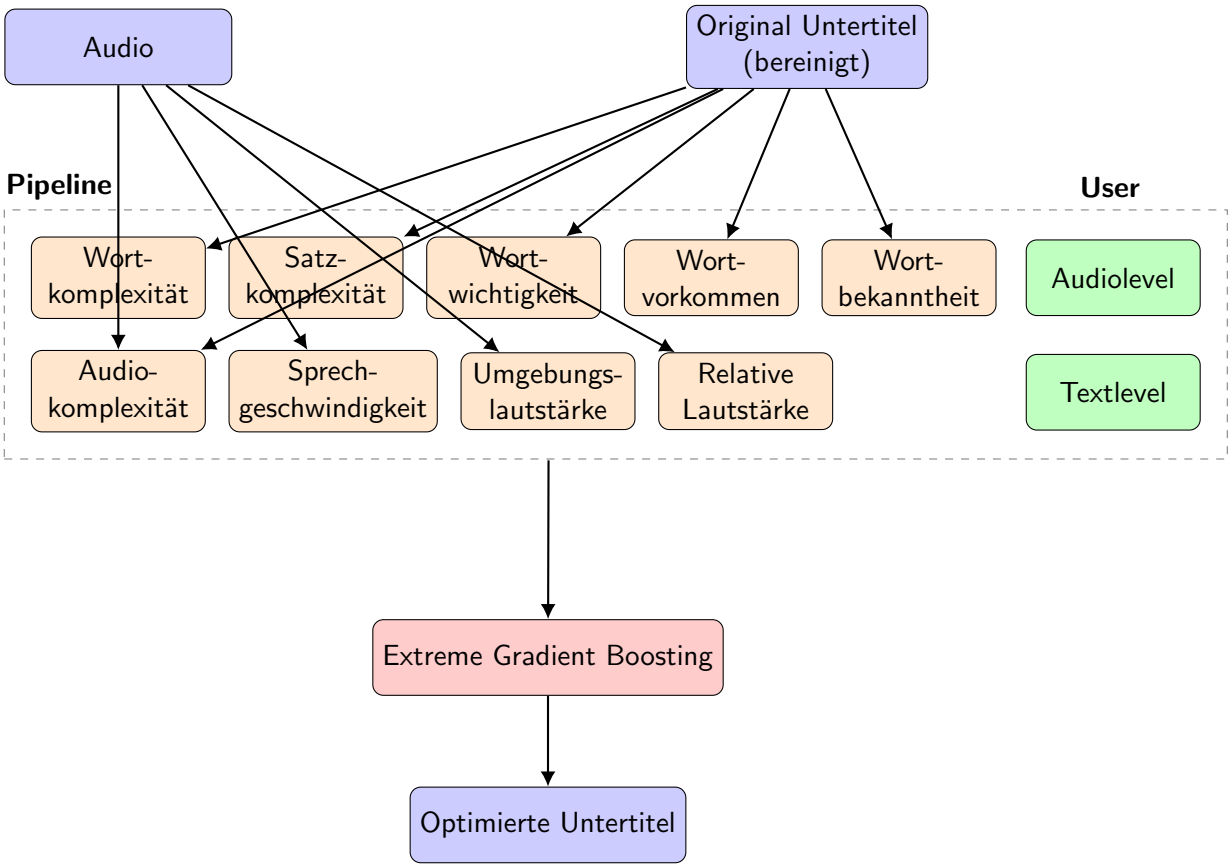


Abbildung 1: Aufbau der Pipeline

4.2 Extraktion der Features

4.2.1 Wortkomplexität

Die Komplexität eines Wortes wird basierend auf dessen CEFR-Level berechnet. Eine Zuordnungstabelle (siehe Tabelle 1) definiert die Werte zwischen 0 und 1. Komplexere Wörter erhalten höhere Werte:

CEFR-Level	**Wortkomplexität**
A1	0.0
A2	0.2
B1	0.4
B2	0.6
C1	0.8
C2	1.0

Tabelle 1: Zuordnung der CEFR-Level zu Komplexitätswerten.

4.2.2 Satzkomplexität

Die Satzkomplexität wird mit ModernBERT (Warner et al., 2024) berechnet, einer schnelleren und moderneren Variante des ursprünglichen BERT (Devlin et al., 2018), um die Schwierigkeit eines Satzes zu bewerten. Dazu wird die Vorhersageunsicherheit für jedes Wort genutzt:

$$Komplexität(s) = \frac{U(s)}{U_{max}} \tag{1}$$

wobei $U(s)$ die kumulative Vorhersageunsicherheit des Satzes s und U_{max} der Maximalwert eines als maximal komplex definierten Referenzsatzes ist, um eine allgemeine Normalisierung zu erhalten.
Die Vorhersageunsicherheit $U(s)$ wird dabei wie folgt berechnet:

$$U(s) = -\sum_{i=1}^{N} p(w_i) \log p(w_i) \tag{2}$$

wobei N die Anzahl der Wörter im Satz ist.
Ein Satz erzielt somit hohe Komplexitätswerte, wenn er viele seltene oder unerwartete Wörter enthält (z.B. ungewöhnliche Wörter oder komplexe Strukturen) und niedrige Werte, wenn die Wörter erwartbar sind (z.B. häufige Wörter oder einfache Strukturen).

4.2.3 Wortwichtigkeit

Die Wichtigkeit eines Wortes innerhalb eines Satzes wird durch Maskierungsvorhersagen mit ModernBERT (Warner et al., 2024) berechnet. Für jeden Satz wird ein Wort maskiert, und die Wahrscheinlichkeit für das Originalwort wird bestimmt:

$$Wichtigkeit(w_i) = 1 - p(w_i|s). \tag{3}$$

Je unerwarteter ein Wort im Kontext ist, desto höher ist seine Wichtigkeit.

4.2.4 Wortvorkommen

Die Häufigkeit eines Wortes im gesamten Video wird wie folgt normalisiert:

$$Vorkommen(w_i) = \frac{\mathrm{A}(w_i)}{\mathrm{A}(max)}. \tag{4}$$

wobei A(w_i) die Häufigkeit des Wortes im gesamten Text und A(max) in der aktuellen Pipeline auf 15 gesetzt ist, da Wörter, die öfter in einem Video vorkommen, als hinreichend bekannt angenommen werden.

4.2.5 Wortbekanntheit

Die Wortbekanntheit basiert auf der normalisierten Zipf-Skala(van Heuven et al., 2014), die die gefühlte Häufigkeit von Wörtern in einer Sprache quantifiziert.
Die Zipf-Bekanntheit wird ermittelt und normiert:

$$\text{Bekanntheit}(w_i) = \frac{\text{Zipf-Bekanntheit}(w_i)}{8} \tag{5}$$

Die Normierung erfolgt durch die Division durch 8 aufgrund des Wertebereichs der Zipf-Skala, der zwischen 0 (sehr selten) und 8 (extrem häufig) liegt.

4.2.6 Audiokomplexität

Im ersten Schritt wird das Audio mit Whisper transkribiert (Radford et al., 2022). Dabei wird ein schlechteres Modell (whisper-tiny, quantisiert auf 8-Bit-Integer) verwendet, um größere Unsicherheiten und Ausreißer zu erfassen. Für jedes Wort w_i wird die Unsicherheitsbewertung wie folgt berechnet:

$$A(w_i) = 1 - p(w_i), \tag{6}$$

wobei $p(w_i)$ die vom Modell vorhergesagte Wahrscheinlichkeit des Wortes ist. Wörter mit hoher Unsicherheit erhalten dadurch höhere Werte.

4.2.7 Sprechgeschwindigkeit

Die Sprechgeschwindigkeit wird durch die Analyse der Silbenrate pro Sekunde für jeden Satz ermittelt. Im Gegensatz zur wortbezogenen Analyse werden hier ganze Sätze betrachtet, da die Geschwindigkeit einzelner Wörter zu stark variieren kann und keine aussagekräftige Messgröße darstellt. Für die Implementierung wird ein größeres, besseres Whisper-Modell verwendet, das präzisere Zeitstempel für jedes Wort liefert.
Für jeden Satz wird die Silbenrate wie folgt berechnet:

$$\text{SPS}(s) = \frac{\sum_{i=1}^{N} \text{Silben}(w_i)}{\text{Dauer}(s)} \tag{7}$$

wobei SPS(s) die Silben pro Sekunde für Satz s, $\sum_{i=1}^{N} \text{Silben}(w_i)$ die Summe der Silben aller Wörter im Satz und Dauer(s) die zeitliche Länge des Satzes in Sekunden ist.
Für die Normierung der Sprechgeschwindigkeit wird eine Sigmoid-Funktion verwendet:

$$\text{Geschwindigkeit}(s) = \frac{1}{1 + e^{-(\text{SPS}(s) - \text{CENTER})/\text{SCALE}}} \tag{8}$$

Die Parameter CENTER $= 5,2$ und SCALE $= 1,2$ basieren auf fundierten wissenschaftlichen Studien. Nitta et al. (2010) konnten nachweisen, dass die durchschnittliche Konversationsrate in Filmen und Serien bei etwa 5,0 Silben pro Sekunde liegt, während Robb et al. (2004) dokumentierten, dass amerikanische Erwachsene im Durchschnitt mit 5,3 Silben pro Sekunde sprechen. Basierend auf diesen Erkenntnissen wurde der Mittelwert von 5,2 als CENTER-Parameter festgelegt. Die Standardabweichung von 1,2 wurde aus den Perzentildaten der Studie abgeleitet, die

zeigen, dass etwa 60 % der natürlichen Sprache zwischen 4,0 und 6,0 Silben pro Sekunde liegt.[1]

Für die nächsten beiden Features wird die Audiospur mittels demucs (Rouard et al., 2023) in Stimmen und Hintergrundgeräusche separiert. Demucs ist ein hybrider Ansatz, der Fourier- und Wavelet-Transformationen mit tiefen neuronalen Netzen kombiniert, um eine präzise Quellentrennung zu erreichen.

4.2.8 Umgebungslautstärke

Die Umgebungslautstärke quantifiziert das Verhältnis zwischen Stimmen- und Hintergrundlautstärke als objektive Metrik für jedes Wort:

$$\text{Verhältnis}(w_i) = \frac{\text{Stimmenlautstärke}(w_i)}{\text{Hintergrundlautstärke}(w_i)} \tag{9}$$

Dabei wird die Lautstärke als Root Mean Square (RMS) der Amplitude des jeweiligen Audiosegments berechnet:

$$\text{Lautstärke}(segment) = \sqrt{\frac{1}{n}\sum_{i=1}^{n} segment_i^2} \tag{10}$$

Ein Verhältnis kleiner als 1 indiziert, dass der Hintergrund dominanter ist als die Stimme, was die Verständlichkeit signifikant reduziert. Um für die adaptive Untertitelanzeige insbesondere diese kritischen Fälle hervorzuheben, wird eine logarithmische Normalisierung implementiert:

$$\text{Umgebungslautstärke}(w_i) = 1 - \frac{\log(1 + \text{Verhältnis}(w_i))}{\log(1 + C)} \tag{11}$$

wobei $C = 4$ als Skalierungsfaktor dient.

4.2.9 Relative Lautstärke

Die relative Stimmenlautstärke erfasst die Variation der Sprecherintensität innerhalb des gesamten Videos.
Für jeden Satz wird die durchschnittliche Stimmenlautstärke (RMS) berechnet und relativ zum globalen Durchschnitt aller Sätze normiert:

$$\text{Verhältnis}(s) = \frac{\text{RMS}(s)}{\text{RMS}_{\text{mean}}} \tag{12}$$

Dieses Verhältnis wird linear auf einen Wertebereich von 0 bis 1 transformiert, wobei 0 als Minimum und 2 (doppelte Durchschnittslautstärke) als Maximum definiert wird:

$$\text{Relative Lautstärke}(s) = \frac{\text{Verhältnis}(s)}{2} \tag{13}$$

Die Berechnung erfolgt auf Satzebene, da natürliche prosodische Variationen einzelner Wörter die Messung auf Wortebene verzerren würden.

[1] Die Abschätzung der Standardabweichung erfolgte anhand der Perzentilverteilung aus Abbildung 3 in Nitta et al. (2010). Bei approximativer Normalverteilung entspricht das 50. Perzentil etwa 5,0 SPS, während etwa 18,7 % 4 SPS und 77,2 % 6 SPS liegen. Dies bedeutet, dass ungefähr ±1 SPS um den Mittelwert einen Bereich von etwa 19 % bis 77 % abdeckt, was näherungsweise einer Standardabweichung in einer Normalverteilung entspricht (bei perfekter Normalverteilung würden ±1 Standardabweichung 68 % abdecken; hier haben wir etwa 58,5 % zwischen 4–6 SPS). Dies legt nahe, dass die Standardabweichung der Sprechgeschwindigkeit bei etwa 1,0 SPS liegt. Zur konservativen Abschätzung wurde der SCALE-Parameter auf 1,2 SPS festgelegt.

4.3 Kontextabhängige Übersetzung

Jeder Satz wird zudem mit OPUS-MT (Tiedemann and Thottingal, 2020) ins Deutsche übersetzt, um später auch zweisprachige Untertitel anzuzeigen. Mit SimAlign (Jalili Sabet et al., 2020) werden die Originalwörter den übersetzten Wörtern zugeordnet, um kontextabhängige Bedeutungen zu berücksichtigen.
Beispiel:
Originalsatz (Englisch): „The bark of the tree was rough."
Deutsche Übersetzung (OPUS-MT): „Die Rinde des Baumes war rau."
Das Alignment würde die Wortpaare wie folgt zuordnen:

- The → Die
- bark → Rinde
- of → des
- the → des
- tree → Baumes
- was → war
- rough → rau

Kommentar: Das Wort *bark* ist ein Homonym, das sowohl *Rinde* als auch *Bellen* bedeuten kann. Die Übersetzung berücksichtigt hier den Kontext des Satzes.

4.4 Extreme Gradient Boosting zur Entscheidungsfindung

Die finale Entscheidung über die Anzeige von Untertiteln trifft am Ende der Pipeline ein Extreme Gradient Boosting Model (Chen and Guestrin, 2016). Ein optionaler Bias, der der Sigmoid-Funktion vorgeschaltet ist, ermöglicht zudem eine zusätzliche Regulation der Anzahl der dargestellten Untertitel während der Nutzung.

4.4.1 Trainingsset

Das für das Training und die Evaluation verwendete Datenset umfasst insgesamt 39.367 Wörter, was etwa fünf Stunden Videomaterial entspricht. Die Daten wurden sowohl vom Autor als auch von weiteren annotierenden Personen manuell gelabelt, um die Notwendigkeit der Untertitelanzeige für jedes Wort zu bestimmen. Die Aufteilung in Trainings- und Testset erfolgte im Verhältnis 80:20, um eine robuste Generalisierung zu gewährleisten und Overfitting zu vermeiden. Die folgende Tabelle gibt einen Überblick über die Verteilung der Daten und die bestehende Klassenimbalance:

Kategorie	**Anzahl**	**Prozent**
Gesamtdatenset	39 367	100 %
Trainingsset	31 493	80,0 %
Testset	7 874	20,0 %
True (Anzeigen)	3 416	8,7 %
False (Nicht-Anzeigen)	35 951	91,3 %
Imbalance Verhältnis (neg:pos)	10,52 : 1	

Tabelle 2: Übersicht über Trainings- und Testset sowie Klassenverteilung.

Um die Generalisierbarkeit des Modells für verschiedene Nutzerprofile zu gewährleisten, wurde das Datenset hinsichtlich der von den Nutzenden auswählbaren Audio- und Sprachverständnislevel (CEFR) diversifiziert. Die Annotationen erfolgten überwiegend durch den Autor, wodurch insbesondere die Kombination C1 und C2 stärker vertreten ist. Die folgende Tabelle zeigt die Verteilung der Wörter auf die jeweiligen Nutzerpräferenz-Kombinationen:

Tabelle 3: Verteilung des Trainingsset nach Nutzerpräferenz (Audio- und Sprachlevel).

Audio-Level	**Sprach-Level**	**Wörter**	**Prozent**
B2	B1	6 629	16,8 %
B2	B2	3 507	8,9 %
C2	C1	22 134	56,3 %
C2	C2	7 097	18,0 %
Gesamt		39 367	100 %

4.4.2 Hyperparameter und Trainingsdetails

Im Projektverlauf erwies sich der Einsatz von Extreme Gradient Boosting (Chen and Guestrin, 2016) gegenüber neuronalen Netzen als besser interpretierbare und leistungsfähigere Lösung. Die Hyperparameteroptimierung erfolgte mittels Bayes'scher Optimierung mit Fokus auf die Maximierung des AUC-PR-Scores. Die finale Parameterkonfiguration lautet:

- **Lernrate:** 0,140
- **Maximale Tiefe:** 7
- **Subsample-Ratio:** 0,923
- **Feature-Subsample:** 0,719
- **L2-Regularisierung:** 7,951
- **Gamma:** 2,345
- **Minimales Blattgewicht:** 6,48
- **Skalierung Positivklasse:** 15,03

Das Modell wurde mit 1.000 Bäumen trainiert und nutzte Early Stopping nach 50 Runden ohne Verbesserung. Die Klassenimbalance wurde durch Skalierung der Positivklasse kompensiert.

5 Ergebnisse

Dieser Abschnitt stellt die Ergebnisse der entwickelten Pipeline und des XGBoost-Modells dar und prüft, ob die zu Beginn formulierte Hypothese bestätigt werden konnte. Dabei wurde das Modell auf dem Testset evaluiert, das 7.874 Wörter (20 % des Gesamtdatensets) umfasst.

5.1 Leistungsbewertung des Modells

Die finale Evaluierung des XGBoost-Modells auf dem Testset liefert die in Tabelle 4 dargestellten Leistungskennzahlen.
Der F2-Score von 0,6122, der den Recall stärker gewichtet als die Präzision, deutet darauf hin, dass das Modell eine gute Fähigkeit besitzt, tatsächlich benötigte Untertitel zu identifizieren (hoher Recall). Dies ist für das Projektziel entscheidend, um sicherzustellen, dass den Nutzenden

Metrik	F1-Score	F2-Score	Balanced Accuracy	ROC-AUC
Wert	0,4936	0,6122	0,8064	0,8927

Tabelle 4: Leistungskennzahlen des XGBoost-Modells.

keine wichtigen Informationen entgehen. Der F1-Score liegt mit 0,4936 merklich niedriger, was auf eine geringere Präzision hindeutet – das Modell generiert also auch eine relevante Anzahl an falsch-positiven Vorhersagen (zeigt Untertitel an, wo sie nicht nötig wären). Die Balanced Accuracy von 0,8064 zeigt eine solide durchschnittliche Leistung über beide Klassen hinweg, auch unter Berücksichtigung der Klassenimbalance. Der ROC-AUC-Wert von 0,8927 ist relativ hoch und bestätigt, dass das Modell eine gute generelle Fähigkeit zur Unterscheidung zwischen den Klassen „Anzeigen“ und „Nicht-Anzeigen“ besitzt.

5.2 Klassifikationsbericht

Der detaillierte Klassifikationsbericht (Tabelle 5) gibt weiteren Aufschluss über die Leistung für die einzelnen Klassen.

Klasse	Precision	Recall	F1-Score	Support
False (Nicht-Anzeigen)	0,97	0,88	0,93	7191
True (Anzeigen)	0,37	0,73	0,49	683
Accuracy			0,87	7874
Macro Avg	0,67	0,81	0,71	7874
Weighted Avg	0,92	0,87	0,89	7874

Tabelle 5: Detaillierter Klassifikationsbericht des XGBoost-Modells.

Die Analyse des Klassifikationsberichts bestätigt die Beobachtungen aus den Gesamtmetriken. Für die Klasse 0 (Nicht-Anzeigen) erzielt das Modell eine exzellente Leistung: Die hohe Präzision (0,97) bedeutet, dass als „Nicht-Anzeigen“ klassifizierte Wörter mit sehr hoher Wahrscheinlichkeit tatsächlich nicht angezeigt werden sollten, während der Recall (0,88) und F1-Score (0,93) ebenfalls stark sind, was auf eine effektive Unterdrückung unnötiger Untertitel hindeutet. Bei Klasse 1 (Anzeigen) zeigt sich das erwartete Trade-off: Der Recall ist mit 0,73 gut, sodass 73 % der tatsächlich benötigten Untertitel erkannt werden, was dem Projektziel dient, keine wichtigen Informationen zu verpassen. Allerdings ist die Präzision mit 0,37 niedrig, was bedeutet, dass viele Untertitel fälschlicherweise angezeigt werden (False Positives), wenn das Modell eine Anzeige vorschlägt. Der niedrige F1-Score von 0,49 für diese Klasse spiegelt diese Diskrepanz zwischen gutem Recall und schwacher Präzision wider.
Die hohe Gesamtgenauigkeit (Accuracy: 0,87) und der hohe gewichtete Durchschnitt (Weighted Avg F1: 0,89) werden stark durch die Leistung auf der dominierenden Klasse 0 beeinflusst. Der Makro-Durchschnitt (Macro Avg F1: 0,71) hingegen, der beide Klassen gleich gewichtet, gibt einen besseren Eindruck der durchschnittlichen Leistung über beide Klassen hinweg und wird durch die schwächere Performance bei Klasse 1 nach unten gezogen. Zusammenfassend lässt sich sagen, dass das Modell sehr gut darin ist, unnötige Untertitel zu vermeiden, aber bei der Identifizierung notwendiger Untertitel zu viele nicht benötigte Untertitel mit anzeigt. Der Fokus auf Recall (via F2-Score und Klassengewichtung) wurde erreicht, jedoch auf Kosten der Präzision für die „Anzeigen“-Klasse.

5.3 Feature Importance Analyse

Ein Vorteil von Gradient Boosting Modellen ist die Möglichkeit, die Wichtigkeit der einzelnen Features für die Modellentscheidungen zu analysieren. Tabelle 6 zeigt die Feature Importance Scores, die angeben, wie stark jedes Feature über alle Bäume hinweg beigetragen hat.

Feature	Importance Score
Sprachlevel der Nutzenden	0,1743
Wortbekanntheit	0,1591
Worthäufigkeit	0,1451
Audioverständnislevel der Nutzenden	0,0905
Wortkomplexität	0,0719
Satzkomplexität	0,0689
Sprechgeschwindigkeit	0,0637
Relative Stimmenlautstärke	0,0618
Umgebungslautstärke	0,0565
Audiokomplexität	0,0554
Wortwichtigkeit	0,0527

Tabelle 6: Feature Importance des XGBoost-Modells.

Die Analyse der Feature Importance zeigt, dass die von den Nutzenden angegebenen Präferenzen (Sprachlevel der Nutzenden) sowie intrinsische Eigenschaften der Wörter (Wortbekanntheit, Worthäufigkeit) den größten Einfluss auf die Vorhersagen des Modells haben. Das Audioverständnislevel der Nutzenden und die Wortkomplexität folgen mit etwas Abstand. Dies deckt sich weiterhin mit der Intuition, dass sowohl die subjektive Einschätzung der Nutzenden als auch die objektiven Schwierigkeitsgrade und die Häufigkeit der Wörter entscheidend dafür sind, ob ein Untertitel benötigt wird.
Die Features Satzkomplexität, Sprechgeschwindigkeit, relative Stimmenlautstärke, Umgebungslautstärke, Audiokomplexität und Wortwichtigkeit zeigen einen geringeren, jedoch noch immer signifikanten Einfluss auf die Modellentscheidungen. Die vergleichsweise geringere Bedeutung der Sprechgeschwindigkeit, der Lautstärke-basierten Features (Umgebungslautstärke, relative Stimmenlautstärke) sowie der Audiokomplexität könnte darauf zurückzuführen sein, dass im genutzten Datenset möglicherweise nicht genügend Varianz in diesen Features vorhanden war, um eine stärkere Differenzierung zu ermöglichen, oder dass die Berechnungsmethoden die relevanten Aspekte nicht optimal erfassen. Die geringere Bedeutung von Satzkomplexität und Wortwichtigkeit im Vergleich zu den reinen Wort-basierten Features legt nahe, dass für die aktuelle Modellierungsaufgabe die auf Wortebene ermittelte Komplexität und Häufigkeit relevanter sind als komplexere Satz- oder Kontextanalysen. Diese Feature Importance Analyse liefert wertvolle Einblicke in die Funktionsweise des Modells und kann als Grundlage für zukünftige Optimierungen der Feature-Extraktion oder zur gezielten Erweiterung des Datensets dienen.

5.4 Einfluss der Trainingssetgröße

Um den Einfluss der verfügbaren Trainingssetgröße auf die Leistung des XGBoost-Modells zu untersuchen, wurde das Modell mit unterschiedlichen Anteilen des Gesamtdatensets trainiert und jeweils auf dem verbleibenden Teil evaluiert. Abbildung 2 zeigt die Entwicklung des F2-Scores in Abhängigkeit von der Anzahl der Wörter im Trainingsset.
Die Analyse des Zusammenhangs zwischen Trainingssetgröße und Modellperformanz zeigt einen deutlichen positiven Trend. Der F2-Score verbessert sich von 0,485 bei der Verwendung von nur 10 % der Daten (ca. 3.900 Wörter) auf 0,612 bei 80 % der Daten (ca. 31.500 Wörter). Der Anstieg ist über den größten Teil des Bereichs zu beobachten, mit einer leichten Abflachung und einem minimalen Rückgang bei 60 % Trainingsanteil, bevor der Score zum Ende hin wieder stärker zunimmt und seinen höchsten Wert bei der größten untersuchten Trainingssetgröße erreicht.
Diese Entwicklung legt nahe, dass das XGBoost-Modell von einer größeren Datenmenge profitiert und eine Sättigung der Leistung mit den aktuell verfügbaren ca. 31.500 Trainingswörtern noch nicht erreicht ist. Eine weitere Vergrößerung des Trainingssets würde sehr wahrscheinlich

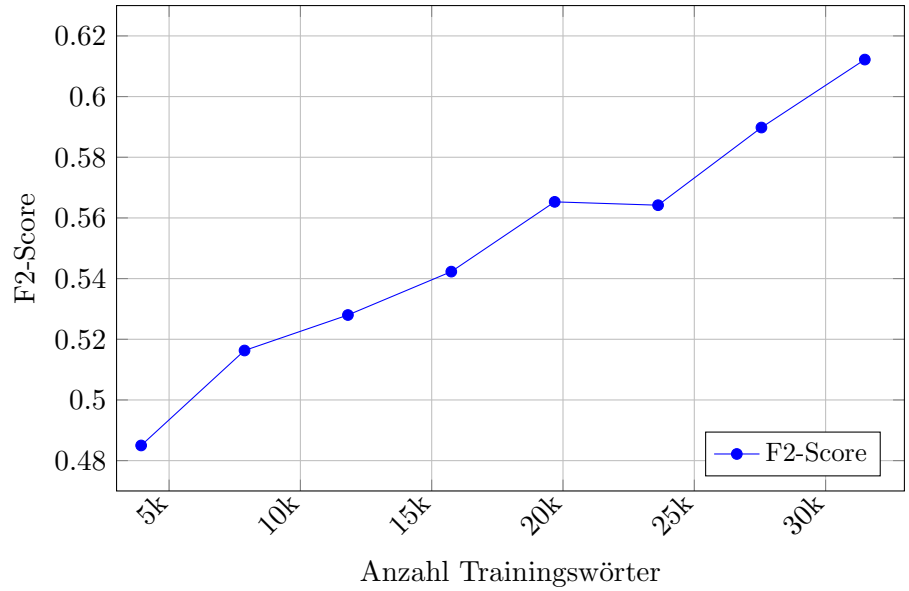


Abbildung 2: Entwicklung des F2-Scores (XGBoost) in Abhängigkeit von der Trainingssetgröße.

zu zusätzlichen Performanzsteigerungen führen. Für zukünftige Arbeiten wäre daher die Evaluation mit noch größeren Datenmengen oder der Einsatz von Data-Augmentation-Techniken vielversprechend, um die Modellleistung weiter zu optimieren.

6 Ergebnisdiskussion

Die erzielten Ergebnisse demonstrieren eindrücklich die grundsätzliche Machbarkeit und das Potenzial adaptiver Untertitelsysteme. Die zentrale Hypothese, dass Untertitel basierend auf einer Kombination aus Audio- und Textfeatures sowie Nutzerpräferenzen bedarfsgerecht angezeigt werden können, konnte im Kern bestätigt werden. Das entwickelte XGBoost-Modell ist in der Lage, die Anzeigehäufigkeit von Untertiteln signifikant zu steuern.
Die detaillierte Leistungsanalyse offenbart jedoch ein differenziertes Bild. Der erreichte F2-Score von 0.6122 und der Recall von 0.73 für die Klasse „Anzeigen“ (True) zeigen, dass das Modell dem gesetzten Ziel, wichtige Informationen zuverlässig anzuzeigen, in hohem Maße gerecht wird. Dies minimiert das Risiko, dass den Nutzenden Verständnisbrücken fehlen. Dem gegenüber steht jedoch die Präzision von lediglich 0.37 für dieselbe Klasse. Dies bedeutet, dass ein erheblicher Anteil der angezeigten Untertitel gemäß der Annotation als nicht notwendig eingestuft wurde (False Positives), was dem Ziel der Reduktion visueller Ablenkung entgegenwirkt. Die exzellente Präzision von 0.97 für die Klasse „Nicht-Anzeigen“ (False) unterstreicht hingegen die Stärke des Modells bei der effektiven Unterdrückung eindeutig unnötiger Untertitel. Der hohe ROC-AUC-Wert (0.8927) belegt zudem die gute generelle Trennfähigkeit des Modells.
Die Feature Importance Analyse (Tabelle 6) liefert wertvolle Hinweise: Die expliziten Nutzerpräferenzen (Sprach- und Audiolevel) sowie grundlegende Wortfeatures (Bekanntheit, Häufigkeit im Video) dominieren die Entscheidung. Features wie Sprechgeschwindigkeit oder Lautstärkeverhältnisse haben einen geringeren Einfluss, was auf mögliche Limitierungen in der Feature-Extraktion oder auf eine unzureichende Varianz dieser Features im aktuellen Datenset hindeuten könnte.
Die Untersuchung des Einflusses der Trainingssetgröße (Abbildung 2) zeigt einen klaren positiven Zusammenhang: Der F2-Score steigt bis zur maximal genutzten Datenmenge von 80 % (ca. 31.500 Wörter) kontinuierlich an. Dies legt nahe, dass das Leistungspotenzial des Modells noch nicht ausgeschöpft ist und weitere Daten zu signifikanten Verbesserungen führen können.
Trotz der vielversprechenden Ergebnisse bestehen klare Ansatzpunkte für Optimierungen:

- **Erweiterung und Diversifizierung des Trainingssets:** Das aktuelle Datenset basiert überwiegend auf Annotationen des Autors, was zu einer starken Gewichtung höherer Verständlichkeitsniveaus (C1/C2) führt (siehe Tabelle 3). Eine Erweiterung um Daten von Nutzenden mit unterschiedlichen Audio- und Sprachverständnislevels sowie aus verschiedenen Genres (Filme, Serien, Dokumentationen) ist essentiell, um die Generalisierbarkeit und Robustheit des Modells zu erhöhen.
- **Verbesserung der Präzision:** Die Reduktion von False Positives bei der Klasse „Anzeigen“ ist ein zentrales Ziel. Dies könnte durch die Verfeinerung bestehender Features oder die Entwicklung neuer Feature erreicht werden.
- **Optimierung der Pipeline-Effizienz:** Die aktuelle Verarbeitungszeit pro Video ist beträchtlich. Eine Optimierung der einzelnen Pipeline-Komponenten, insbesondere durch stärkere GPU-Nutzung und effizientere Algorithmen, ist für eine praktische Anwendbarkeit notwendig.

7 Fazit und Ausblick

Die vorliegende Arbeit hat erfolgreich ein System zur adaptiven Steuerung von Untertiteln entwickelt und evaluiert. Die Kernfrage, ob Untertitel basierend auf Audio- und Textverständlichkeit sowie Nutzerpräferenzen dynamisch ein- und ausgeblendet werden können, konnte positiv beantwortet werden. Die entwickelte Pipeline, die ein Extreme Gradient Boosting (XGBoost) Modell nutzt, stellt einen vielversprechenden Ansatz dar, um die traditionellen Nachteile permanenter oder gänzlich fehlender Untertitel zu überwinden.
Die quantitative Evaluation zeigt die Stärken und Schwächen des aktuellen Systems auf. Der Fokus auf einen hohen Recall (0.73 für Klasse 1), unterstützt durch die Optimierung auf den F2-Score (0.6122), stellt sicher, dass Nutzende wichtige Informationen mit hoher Wahrscheinlichkeit angezeigt bekommen. Die Kehrseite ist die niedrige Präzision (0.37 für Klasse 1), die zu einer übermäßigen Anzeige von Untertiteln führt und das Potenzial zur Reduzierung visueller Ablenkung limitiert. Dennoch belegen die solide Balanced Accuracy (0.8064) und der hohe ROC-AUC-Wert (0.8927) die grundsätzliche Fähigkeit des Modells, zwischen notwendigen und nicht notwendigen Untertiteln zu differenzieren.
Die ursprüngliche Hypothese bezüglich der ausreichenden Repräsentativität der gewählten Features muss differenziert betrachtet werden. Während die Features eine Basis für die Entscheidung liefern, deutet die Performance, insbesondere die Präzisionslimitierung, darauf hin, dass die aktuelle Feature-Repräsentation noch Optimierungspotenzial birgt oder das Modell von umfangreicheren Daten profitieren würde. Die Analyse der Trainingssetgröße unterstreicht letzteren Punkt deutlich: Die Leistung steigt bis zur maximal verfügbaren Datenmenge an, was stark für die Akquise weiterer annotierter Daten spricht.
Ein interessantes Nebenprodukt der Pipeline ist die Trennung von Stimmen und Hintergrundgeräuschen mittels demucs. Diese separierten Audiospuren ermöglichen zudem bereits ein weiteres nützliches Feature zur Verbesserung der Verständlichkeit: die individuelle Anpassung der relativen Lautstärke zwischen Sprecherstimmen und Hintergrundkulisse durch die Nutzenden.
Für zukünftige Forschungs- und Entwicklungsarbeiten ergeben sich klare Richtungen:

- **Datenerweiterung und -diversifizierung:** Dies ist der vielversprechendste Weg zur Leistungssteigerung. Ein größeres und vielfältigeres Datenset (mehr Annotierende, verschiedene Nutzerprofile, unterschiedliche Genres und Sprecherstile) ist essentiell.
- **Feature Engineering und -selektion:** Die Untersuchung zusätzlicher oder verfeinerter Features (z.B. komplexere linguistische Features, Berücksichtigung längerer Kontexte, robustere Audioanalysen) sowie eine kritische Evaluation der bestehenden Features könnten die Präzision verbessern.
- **Untersuchung offener Forschungsfragen:** Systematische Analysen sollten adressieren, (a) welche Auswirkungen unterschiedliche Genres (z.B. Actionfilm vs. Drama) auf die Modellperformance haben, (b) wie sich verschiedene Verteilungen von Sprach-/Audioniveaus im Trainingsset auswirken und (c) welche Leistung auf gänzlich unbekannten Sprach-/Audioniveaus erzielt wird.
- **Nutzerstudien:** Subjektive Bewertungen durch Endnutzende sind notwendig, um die tatsächliche Verbesserung des Seherlebnisses und der Verständlichkeit zu validieren und zusätzlich zu prüfen, ob sich durch die Nutzung auch ein signifikanter Lerneffekt im Hinblick auf die Englischkenntnisse einstellt.

Zusammenfassend legt diese Arbeit eine solide Grundlage für adaptive Untertitelsysteme. Sie demonstriert die Machbarkeit, identifiziert die zentralen Herausforderungen und weist klare Wege für zukünftige Verbesserungen auf. Der entwickelte Ansatz ist prinzipiell sprachunabhängig konzipiert und könnte somit mit entsprechenden Anpassungen auf andere Sprachen übertragen werden.

8 Literaturverzeichnis

Wataru Akahori, Tatsunori Hirai, and Shigeo Morishima. Dynamic subtitle placement considering the region of interest and speaker location. In *Proceedings of the 12th International Joint Conference on Computer Vision, Imaging and Computer Graphics Theory and Applications (VISIGRAPP 2017)*, pages 102–109, 2017. doi: 10.5220/0006262201020109.

Bundesfachstelle Barrierefreiheit. Untertitel für barrierefreie inhalte, 2022. URL `https://www.bfit-bund.de/SharedDocs/Downloads/DE/Praxistipps-und-Leitfaeden/Untertitel.pdf?__blob=publicationFile&v=3`. Zugriff am 27.04.2025.

Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, KDD '16, page 785–794. ACM, August 2016. doi: 10.1145/2939672.2939785. URL `http://dx.doi.org/10.1145/2939672.2939785`.

Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: pre-training of deep bidirectional transformers for language understanding. *CoRR*, abs/1810.04805, 2018. URL `http://arxiv.org/abs/1810.04805`.

Benjamin M. Gorman, Michael Crabb, and Mike Armstrong. Adaptive subtitles: Preferences and trade-offs in real-time media adaption. In *Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems*, pages 1–11. Association for Computing Machinery, 2021. doi: 10.1145/3411764.3445509. URL `https://discovery.dundee.ac.uk/ws/portalfiles/portal/55939112/chi21b_sub3062_cam_i50_2_.pdf`.

Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Computation*, 9 (8):1735–1780, 1997.

Yongtao Hu, Jan Kautz, Yizhou Yu, and Wenping Wang. Speaker-Following Video Subtitles. volume 11, pages 32:1–32:17. ACM, 2014.

Masoud Jalili Sabet, Philipp Dufter, François Yvon, and Hinrich Schütze. SimAlign: High quality word alignments without parallel training data using static and contextualized embeddings. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: Findings*, pages 1627–1643, Online, November 2020. Association for Computational Linguistics. URL `https://www.aclweb.org/anthology/2020.findings-emnlp.147`.

Andrej Karpathy. The unreasonable effectiveness of recurrent neural networks. *Blog post*, May 2015.

Kuno Kurzhals, Fabian Göbel, Katrin Angerbauer, Michael Sedlmair, and Martin Raubal. A view on the viewer: Gaze-adaptive captions for videos. In *Proceedings of the 2020 CHI Conference on Human Factors in Computing Systems (CHI '20)*, pages 1–12, Honolulu, HI, USA, 2020. Association for Computing Machinery. ISBN 978-1-4503-6708-0. doi: 10.1145/3313831.3376266.

Haruhiko Nitta, Hironobu Okazaki, and Walter Klinger. Speech rates and a word recognition ratio for listening comprehension of movies. *Studies in the Humanities: The Journal of the Senshu University Research Society*, 87:171–198, 2010.

Preply. Survey: Why america is obsessed with subtitles, 2022. URL `https://preply.com/en/blog/americas-subtitles-use/`. Zugriff am 27.04.2025.

Alec Radford, Jong Wook Kim, Tao Xu, Greg Brockman, Christine McLeavey, and Ilya Sutskever. Robust speech recognition via large-scale weak supervision, 2022. URL `https://arxiv.org/abs/2212.04356`.

Michael P. Robb, Margaret A. Maclagan, and Yang Chen. Speaking rates of american and new zealand varieties of english. *Clinical Linguistics & Phonetics*, 18(1):1–15, 2004.

Simon Rouard, Francisco Massa, and Alexandre Défossez. Hybrid transformers for music source separation. In *ICASSP 23*, 2023.

Florian Schmidt-Weigand, Andrea Kohnert, and Ulrich Glowalla. Effects of subtitles, complexity, and language proficiency on multimedia learning. *Journal of Media Psychology*, 29(2):76–85, 2017. doi: 10.1027/1864-1105/a000208. URL `https://doi.org/10.1027/1864-1105/a000208`.

Jörg Tiedemann and Santhosh Thottingal. OPUS-MT — Building open translation services for the World. In *Proceedings of the 22nd Annual Conferenec of the European Association for Machine Translation (EAMT)*, Lisbon, Portugal, 2020.

Walter J. B. van Heuven, Paweł Mandera, Emmanuel Keuleers, and Marc Brysbaert. A new and improved word frequency database for british english. *Quarterly Journal of Experimental Psychology*, 67(6):1176–1190, 2014. doi: 10.1080/17470218.2013.850521.

Ashish Vaswani, Noam M. Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Neural Information Processing Systems*, 2017.

Benjamin Warner, Antoine Chaffin, Benjamin Clavié, Orion Weller, Oskar Hallström, Said Taghadouini, Alexis Gallagher, Raja Biswas, Faisal Ladhak, Tom Aarsen, Nathan Cooper, Griffin Adams, Jeremy Howard, and Iacopo Poli. Smarter, better, faster, longer: A modern bidirectional encoder for fast, memory efficient, and long context finetuning and inference, 2024. URL `https://arxiv.org/abs/2412.13663`.

9 Unterstützungsleistungen

Die gesamte Entwicklung der Pipeline sowie des neuronalen Netzes wurde vollständig eigenständig durchgeführt. Die Konzeption, Implementierung und Evaluierung basierten ausschließlich auf eigenen Ideen und Ansätzen.
Zur Unterstützung bei der schriftlichen Ausarbeitung und zur Überprüfung von Konzepten sowie Programmteilen wurden verschiedene KI-Modelle eingesetzt:

- **ChatGPT-4o/4o mini:** Verfassung der schriftlichen Arbeit. Erklärung verschiedener Verfahren rund um ML/AI. Hilfe bei der Konzeption der Pipeline.
- **Gemini 2 Experimental:** Hilfe bei der Programmierung des Codes.
- **Perplexity (Claude 3.5 Sonnet/OpenAI o1-Preview):** Siehe Gemini.